

【人工智能】期末复习 重点知识点总结

试卷共有15道题，四种题型：

1、名词解释题（不超过五个字的概念）

2、简答题（包涵计算）

鲁滨逊归结原理、wuzi? 置换?

1. 倒推值计算方法、
2. 代价树每个结点的代价的算法：最大代价法、和代价法
3. α - β 剪枝、

3、证明题

4、综合题

小小tips

理解就可、不用和课本一模一样、说的正确就行

千万别空着，有步骤分、可以找分

书、课后习题、itc习题多看看

老师没有讲的 就不考

一、知识表示的基本方法

非结构化方法：一阶谓词逻辑，产生式规则

结构化方法：语义网络，框架

其他方法：状态空间法，问题规约法

二、人工智能三大流派

(1)符号主义学派：

认识的基元是符号，认识过程就是符号运算和推理；

代表人物：纽厄尔，西蒙；

代表成果：人工定理证明，人工智能语言LISP，鲁滨逊归结原理，专家系统。

(2)连接主义学派：

思维的基元是神经元，而不是符号，思维的过程是神经元的连接活动，而不是符号运算的过程；

代表人物：麦卡洛克，霍普菲尔德；

代表成果：单层感知机，Hopfield网络，BP网络。

(3)行为主义学派，

行为主义学派认为人工智能起源于控制论，智能取决于感知与行为，取决于对外部复杂环境的适应；

代表任务及成果：布鲁克斯研制的六角机器虫。

三、合一置换



概念

置换

- 替换乘法

- 设有2个替换:

- $\theta = \{ t_1/x_1, t_2/x_2, \dots, t_n/x_n \}$

- $\lambda = \{ u_1/y_1, u_2/y_2, \dots, u_m/y_m \}$

- 令: $\mu = \{ t_1 \cdot \lambda/x_1, t_2 \cdot \lambda/x_2, \dots, t_n \cdot \lambda/x_n, u_1/y_1, u_2/y_2, \dots, u_m/y_m \}$

⑧

置换的例题

CSDN @乐心唯帅



概念

置换

- 当 $y_i = x_j$ 时, 从 μ 中删除 u_i/y_i

- 当 $t_i \cdot \lambda = x_i$ 时, 从 μ 中删除 $t_i \cdot \lambda/x_i$

- 剩余元素所构成的集合仍然是一个替换, 称为 θ 与 λ 的乘积, 记作: $\theta \cdot \lambda$

⑨

CSDN @乐心唯帅



例子

置换

例1、设有替换:

$\theta = \{ f(y)/x, z/y \}$

$\lambda = \{ a/x, b/y, y/z \}$

求: $\theta \cdot \lambda$

解:

$\mu = \{ f(b)/x, y/y, a/x, b/y, y/z \}$

$\theta \cdot \lambda = \{ f(b)/x, y/z \}$

⑩

CSDN @乐心唯帅



• 合一

- 设有公式集: $F = \{ F1, F2, \dots, Fn \}$, 若存在一个置换 θ , 使得
- $F1 \theta = F2 \theta = \dots = Fn \theta$
- 则称 θ 为 F 的一个合一置换, 且称 $F1, F2, \dots, Fn$ 是可合一的。



例2、设 $F = \{ P(x, y, f(y)), P(a, g(x), z) \}$,
证明: $\lambda = \{ a/x, g(a)/y, f(g(a))/z \}$ 是 F 的一个合一。

证:

$$(1) P(x, y, f(y))\lambda = P(a, g(a), f(g(a)))$$

$$(2) P(a, g(x), z)\lambda = P(a, g(a), f(g(a)))$$

故 λ 是 F 的合一。

二元归结式证明过程

四、产生式表示法（不确定性推理方法里的说法）

1、产生式系统的组成

(1) 一个综合数据库, 又称事实库, 用于存放输入的事实, 从外部数据库输入的事实、中间结果、最后结果;

(2) 一组产生式规则, 描述某领域内知识的产生式集合;

(3) 一个控制系统, 包含推理方式和控制策略, 又称推理机或推理引擎。

2、专家系统推理过程和结果

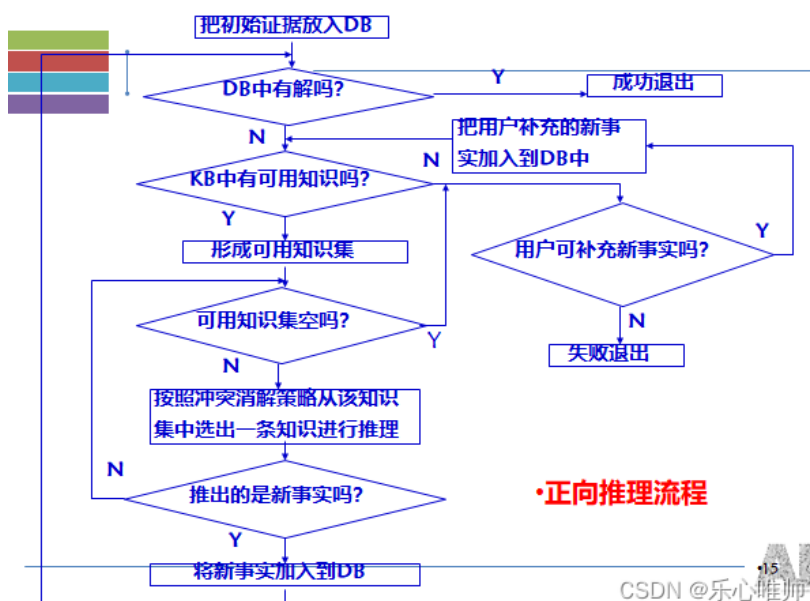


产生式系统的基本过程

- 过程production
- $Data \leftarrow$ 初始数据库
- Until Data满足结束条件 Do
- { 在规则集中选择一条应用于Data的规则R
- $Data \leftarrow$ R应用到Data得到的结果, 写入数据库
- }

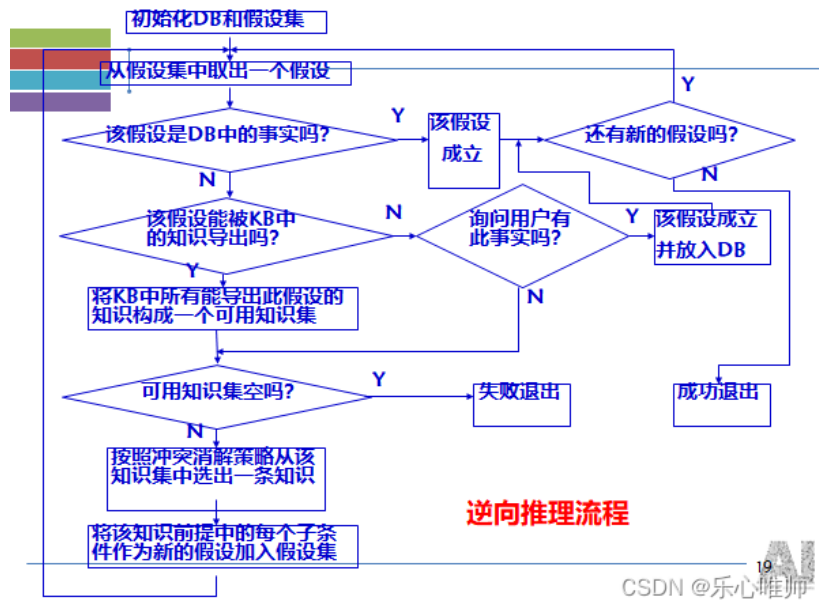
3、正向推理

也称为数据驱动推理或前向链推理



4、逆向推理

亦称为目标驱动推理或逆向链推理



5、知识匹配

五、框架、语义网

(了解如何构建)

框架：横向、纵向联系

匹配、继承方法

有例题

六、状态空间图

构建状态空间图来问题求解 盲目搜索 得到解、如何表示出来

七、与或图：搜索

1、搜索的概念

依靠经验，利用已有知识，根据问题的实际情况，不断寻找可利用知识，从而构造一条代价最小的推理路线，使问题得以解决的过程称为搜索。

2、启发式搜索与盲目性搜索的区别

(1)盲目搜索是指在搜索之前就预定好控制策略，整个搜索过程中的策略不变，即使搜索出来的中间信息有利用价值，其搜索过程中的策略不再改变，效率低，灵活性差，不利于复杂问题求解。

(2)智能搜索是指可以利用搜索过程中得到的中间信息（与问题相关的信息）来引导搜索过程向最优方向发展的算法。

3、启发式信息的概念、（简答、名词解释）

用于指导搜索过程且与具体问题求解有关的信息称为启发信息

启发信息作用分类：

1. 用于决定先扩展哪一个节点
2. 在扩展节点时，用于决定要生成哪一个或哪几个后继节点
3. 用于确定某些应该从搜索树中抛弃或修建的节点

4、启发函数的概念

在扩展节点时，用来描述节点重要程度的函数称为估价函数，一般形式为 $f(x)=g(x)+h(x)$ 。其中， $g(x)$ 为初始节点 S_0 到节点 x 已实际付出的代价， $h(x)$ 是从节点 x 到目标节点 S_g 的最优路径的估计代价，启发信息主要由 $h(x)$ 来体现，故把它称为启发函数。

5、A算法和A*算法基本原理和区别

A算法

在状态空间搜索中，如果每一步都利用估价函数 $f(n)=g(n)+h(n)$ 对Open表中的节点进行排序，则称为A算法。它是一种为启发式搜索算法

类型：

全局择优：从Open表中的所有节点中选择一个估价函数值最小的进行扩展

局部择优：仅从刚生成的子节点中选择一个估价函数值最小的进行扩展。

A*算法

对在A算法的基础上，选了一个比较特殊的估价函数，对节点 n 定义 $f^*(x)=$

$g^*(x)+h^*(x)$ ，表示从 S_0 开始通过节点 x 到 S_g 的一条最佳路径的代价， g 是 g^* 的估计， h 是 h^* 的估计。 $g(x)$ 是对最小代价 $g^*(x)$ 的估计，且 $g(x)>0, g(x)\geq g^*(x)$ ，

$h(x)$ 为 $h^*(x)$ 的下界，即对所有的 x 存在 $h(x)\leq h^*(x)$

八、与或树

1、与或树的有序搜索

盲目搜索：没有考虑代价，所求得解树不一定是代价最小的解树，即不是最优解树。

启发式搜索：要多看几步，计算一下扩展一个节点可能要付出的代价，以选择代价最小的节点进行扩展。

2、希望树的概念

在有序搜索中，应选择那些最有希望成为最优解树一部分的节点进行扩展。我们称这些节点构成的树为希望树。

全局择优、基于希望树的搜索？？？

3、解树的代价计算

最大代价法计算、和代价法计算



解树的代价

设 $g(x)$ 表示节点 x 的代价， $c(x,y)$ 表示节点 x 到其子节点 y 的代价。

(1)若 x 是终叶节点，则 $g(x)=0$

(2)若 x 是或节点，其子节点依次为 y_1, y_2, \dots, y_n ，则有：

$$g(x) = \min\{c(x, y_i) + g(y_i)\} \\ 1 \leq i \leq n$$



解树的代价

(3)若 x 是与节点，其子节点依次为 y_1, y_2, \dots, y_n ,

则有：

$$\text{和代价法: } g(x) = \sum_{i=1}^n (c(x, y_i) + g(y_i))$$

$$\text{最大代价法: } g(x) = \max_{1 \leq i \leq n} \{c(x, y_i) + g(y_i)\}$$



解树的代价

(4)若 x 不可扩展，则： $g(x) = \infty$

若问题有解的话，则子节点的代价可以推算出父节点的代价，直到初始节点的代价，SO的代价就是解树的代价。

九、博弈树（很重要）：

1、博弈树的概念

在博弈过程中，己方的各种攻击方案为“或”关系，而对方的应着方案为“与”关系。描述博弈过程的“与/或”树称为博弈树。

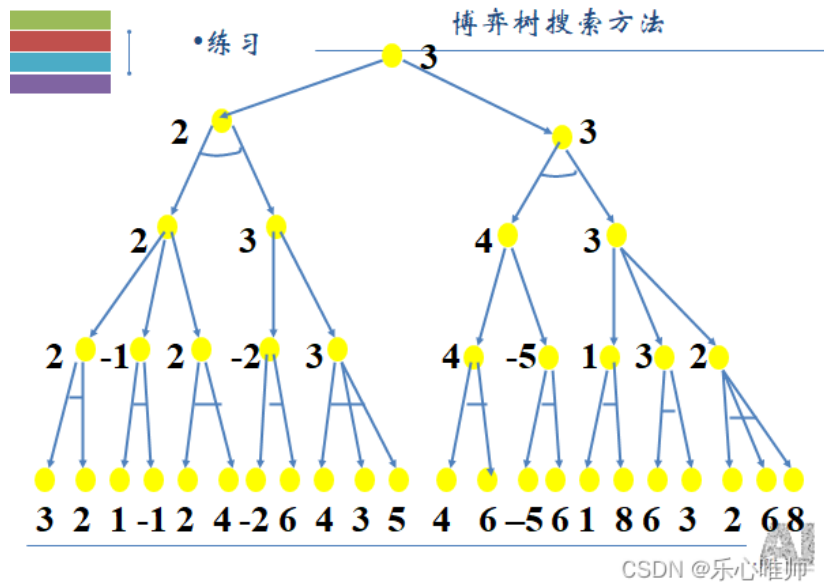
根节点是初始状态

2、极大极小分析法（很重要）

根据所求解问题的特殊信息设计合适的估价函数，计算当前博弈树中所有端节点的得分，该分数称为静态估价值。

根据端节点的估值推算出其父节点的分数：

1. 若父节点为“或”节点，则其分数等于其所有子节点分数的最大值。
2. 若父节点为“与”节点，则其分数等于其所有子节点分数的最小值。
3. 计算出的父节点的分数值称为倒推值。
4. 如果一个方案能获得较大的倒推值，则它就是当前最好的行动方案。




3、a-b剪枝法

一个“与”节点取当前子节点的最小值作为其倒推值的上界，称该值为 β 值。

一个“或”节点取当前子节点的最大值作为其倒推值的下界，称该值为 α 值。


– 如果“或”节点 x 的 α 值不能降低其父节点的 β 值，即： $\alpha \geq \beta$

则应停止搜索节点 x 的其余子节点，并使 x 的倒推值为 α 。这种技术称为 β 剪枝。




如果“与”节点 x 的 β 值不能升高其父节点的 α 值，即： $\beta \leq \alpha$

则应停止搜索节点 x 的其余子节点，并使 x 的倒推值为 β 。这种技术称为 α 剪枝。



CSDN @乐心唯帅

例：对于下面的博弈树进行剪枝



$\alpha - \beta$ 剪枝示例

CSDN @乐心唯帅

十、不确定性知识表示

1、不确定性推理的概念

不确定性推理泛指除精确推理以外的其他各种推理问题。包括不完备、不精确知识的推理、模糊知识推理，非单调性推理等。

(只求概念理解、习题会做就行，涉及比较少、因为难度较大)

可信度推理、bayes推理、概率推理

课后习题也看一看

十一、机器学习

1、决策树

- **决策树** 是一种由节点和边构成的用来描述分类过程的层次数据结构。
- **根节点**：表示分类的开始
- **叶节点**：表示一个实例的结束
- **中间节点**：表示相应实例中的某一属性
- **边代表**：某一属性可能的属性值
- **路径**：从根节点到叶节点的每一条路径都代表一个具体的实例，并且 **同一路径** 上的所有属性之间为合取关系，**不同路径** (即一个属性的不同属性值) 之间为析取关系。

2、ID3算法

信息熵的概念

信息熵是对信息源整体不确定性的度量。假设S为样本集，S中所有样本的类别有k种，如 y_1, y_2, \dots, y_k ，各种类别样本在S上的概率分布分别为 $P(y_1), P(y_2), \dots, P(y_k)$ ，则S的信息熵可定义为：

$$\begin{aligned} E(S) &= -P(y_1)\log P(y_1) - P(y_2)\log P(y_2) - \dots - P(y_r)\log P(y_r) \\ &= -\sum_{j=1}^k P(y_j)\log P(y_j) \end{aligned}$$

CSDN @乐心唯帅

信息增益的概念

- 信息增益(information gain)是对两个信息量之间的差的度量。其讨论涉及到样本集S中样本的结构。
- 对S中的每一个样本，除其类别外，还有其条件属性，或简称为属性。若假设S中的样本有m个属性，其属性集为 $X=\{x_1, x_2, \dots, x_m\}$ ，且每个属性均有r种不同的取值，则我们可以根据属性的不同取值将样本集S划分成r个不同的子集 S_1, S_2, \dots, S_r 。
- 此时，可得到由属性 x_i 的不同取值对样本集S进行划分后的加权信息熵。

$$E(S, x_i) = \sum_{t=1}^r \frac{|S_t|}{|S|} \times E(S_t)$$

CSDN @乐心唯帅

- 其中，t为条件属性 x_i 的属性值； S 为 $x_t=t$ 时的样本子集； $E(S_t)$ 为样本子集 S_t 信息熵； $|S|$ 和 $|S_t|$ 分别为样本集S和样本子集 S_t 的大小，即样本个数。
- 有了信息熵和加权信息熵，就可以计算信息增益。所谓信息增益就是指 $E(S)$ 和 $E(S, x_i)$ 之间的差，即

$$\begin{aligned} G(S, x_i) &= E(S) - E(S, x_i) \\ &= E(S) - \sum_{t=1}^r \frac{|S_t|}{|S|} \times E(S_t) \end{aligned}$$

CSDN @乐心唯帅

信息增益所描述的是信息的不确定性，其值越大，信息的不确定性越高。

3、SVM

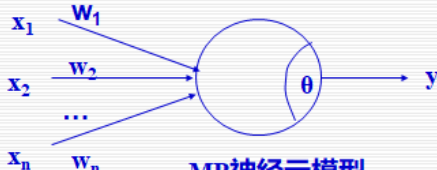
(了解概念即可、分类的基本思想：升维、画超平面、)

十二、神经网络

1、人工神经元基本计算方法和公式（很重要）、

一、人工神经网络基础

人工神经元的结构



MP神经元模型

MP模型是于1943年提出的一种将神经元看作二进制阈值元件的简单模型。

人工神经元是一个具有多输入，单输出的非线性器件。

其输入为： $\sum_{i=1}^n w_i x_i$

其输出为： $y = f(\sigma) = f(\sum_{i=1}^n w_i x_i - \theta)$

CSDN @乐心唯帅

2、各种激励函数（了解）




一、人工神经网络基础

常用的人工神经元模型

根据功能函数的不同，可得不同的神经元模型。

阈值型(Threshold)

这种模型的神经元没有内部状态，作用函数 f 是一个阶跃函数，他表示激活值 σ 和输出之间的关系。




一、人工神经网络基础

常用的人工神经元模型

分段线性强饱和型(Linear Saturation)

这种模型又称为伪线性，其输入/输出之间在一定范围内满足线性关系，一直延续到输出为最大值1为止。但当达到最大值后，输出就不再增加。




一、人工神经网络基础

常用的人工神经元模型

S型(Sigmoid)

这是一种连续的神经元模型，其输入输出特性常用指数、对数或双曲正切等S型函数表示。它反映的是神经元的饱和特性。






一、人工神经网络基础

常用的人工神经元模型

子阈累积型(Subthreshold Summation)

也是一个非线性函数，当产生的激活值超过T值时，该神经元被激活产生反应。在线性范围内，系统的反应是线性的。



CSDN @乐心唯帅

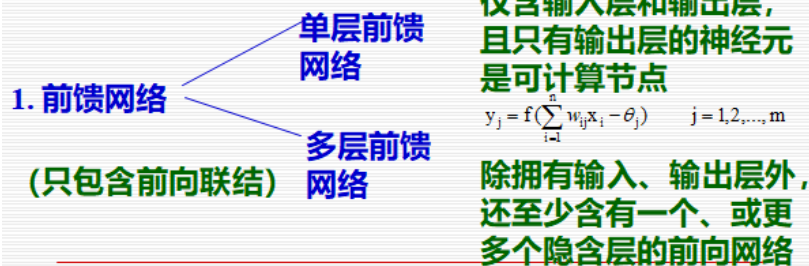
3、前馈问题、反馈模型的基本拓扑结构和它们之间的区别

3、前馈网络的基本拓扑结构




二、人工神经网络的互联结构


人工神经网络的互连结构（或称拓扑结构）是指单个神经元之间的连接模式，它是构造神经网络的基础，也是神经网络诱发偏差的主要来源。从互连结构的角



CSDN @乐心唯帅

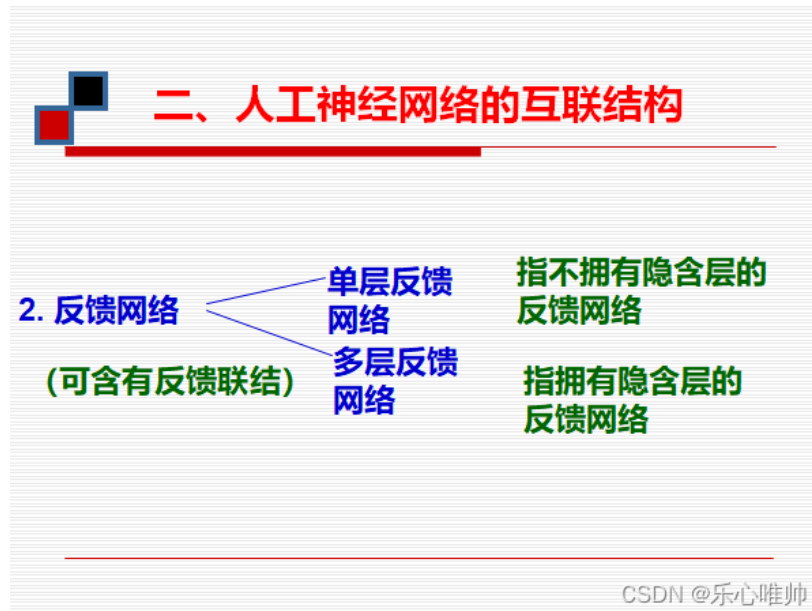


CSDN @乐心唯帅



CSDN @乐心唯帅

4、反馈网络的基本拓扑结构



CSDN @乐心唯帅

5、BP网络模型

双向传播问题：正向传播的作用、逆向传播的作用、两者之间的区别

正向传播：输入信息由输入层传至隐层，最终在输出层输出。

反向传播：修改各层神经元的权值，使误差信号最小。

6、hopfied网络

全连接、反馈网络



3. Hopfield网络模型

离散Hopfield网络模型

- o 在 Hopfield 网络中，虽然神经元自身无连接，但由于每个神经元都与其他神经元相连；
- o 即每个神经元的输出都将通过突触连接权值传递给别的神经元，同时每个神经元又都接受其他神经元传来的信息；
- o 这样对每个神经元来说，其输出经过其他神经元后又有可能反馈给自己，因此 Hopfield 网络是一种反馈神经网络。

CSDN @乐心唯帅

7、CNN

1) 卷积、卷积核的概念

卷积 (convolution) 在卷积神经网络中的主要作用是实现卷积操作，形成网络的卷积层。

卷积操作的基本过程是：针对图像的某一类特征，先构造其特征过滤器 (FF)，然后利用该过滤器对图像进行特征提取，得到相应特征的特征图 (FM)。依此针对图像的每一类特征，重复如上操作，最后得到由所有特征图构成的卷积层。

特征过滤器也称为卷积核 (Coiling Kernel, CK)，它实际上是由相关神经元连接权值所形成的一个权值矩阵，该矩阵的大小由卷积核的大小确定。卷积核与特征图之间具有——对应关系，一个卷积核唯一地确定了一个特征图，而一个特征图也唯一地对应着一个卷积核。

2) 池化、池化层的概念

池化层 (Pooling Layer) 也叫子采样层 (Subsample Layer) 或降采样 (downsampling)，其主要作用是利用子采样 (或降采样) 对输入图像的像素进行合并，得到池化层的特征图谱。

池化操作的一个重要概念是池化窗口或子采样窗口。所谓池化窗口是指池化操作所使用的一个矩形区域，池化操作利用该矩形区域实现对卷积层特征图像素的合并。

例如，一个 8×8 的输入图像，若采用大小为 2×2 的池化窗口对其进行池化操作，就意味着原图像上的 4 个像素将被合并为 1 个像素，原卷积层中的特征图经池化操作后将缩小为原图的 $1/4$ 。

池化操作的基本过程是：从特征图的左上角开始，按照池化窗口，先从左到右，然后再从上向下，不重叠地依次扫过整个图像，并同时利用子采样方法进行池化计算。

常用的池化方法有最大池化 (max pooling) 法、平均池化 (mean pooling) 法和概率矩阵池化 (stochastic pooling) 法等。这里主要讨论最大池化法和平均池化法。

3) 卷积与池化的计算方法